
Modelo Probabilístico

Tópicos Especiais em Recuperação de Informações

Prof^a. Solange Pertile

21/09/15

Fontes:

Prof. Viviane Moreira (UFRGS)

Prof. Jairo de Souza (UFJF)

Relembrando Modelo Booleano...

- Consultas usando operadores booleanos
- Documentos casam ou não casam
- Boa para usuários especialistas com um entendimento preciso das suas necessidades e da coleção
- Boa para aplicações: aplicações podem facilmente processar milhares de resultados.
- Ruim para a maioria dos usuários
- Incapazes de escrever consultas Booleanas (ou são, mas acham muito trabalhoso)
- Não querem procurar em milhares de resultados
 - Principalmente quando se trata de busca na Web

Relembrando Modelo Vetorial...

- ✓ Vector space model (VSM)
- ✓ Associa peso aos termos de indexação.
- ✓ Atribui escores aos documentos.
- ✓ Possibilita *ranking* dos resultados da consulta.

Modelo Probabilístico

- ✓ Proposto em 1976 por Robertson e Sparck;
- ✓ Propõe uma solução ao problema de RI com base na teoria das probabilidades.

Ideia Fundamental

- A partir de uma consulta do usuário, existe um conjunto de documentos que contém exatamente os documentos relevantes (**resposta ideal**) e nenhum outro;
- Dada uma descrição desse **conjunto resposta ideal**, poderíamos recuperar os documentos relevantes;
- Quais são essas propriedades dessa descrição? Resposta: não sabemos! Tudo que sabemos é que existem termos de indexação para caracterizar tais propriedades.

Ideia Fundamental

- Problema:
 - Essas propriedades não são conhecidas na hora da consulta!
 - É necessário um esforço para conseguir uma estimativa inicial dessas propriedades.
- Essa estimativa inicial nos permite gerar uma descrição probabilística preliminar do **conjunto resposta ideal**, que pode ser utilizado para recuperar um primeiro conjunto de documentos.

Ideia Fundamental

Por exemplo:

- O usuário pode ver os documentos recuperados e decidir quais são relevantes e quais não são;
- O sistema pode então utilizar essa informação para refinar a descrição do conjunto resposta ideal;
- Repetindo-se esse processo muitas vezes, espera-se que a descrição do conjunto resposta ideal fique mais precise;
- **IMPORTANTE:** é necessário estimar, no início, a descrição do **conjunto resposta ideal**.

Ranqueamento

- Como calcular a medida de similaridade? Como criar uma função que irá ranquear os resultados?
 - d é um documento da coleção
 - R representa que o documento é relevante
 - NR representa que o documento não é relevante
 - Os documentos serão ranqueados de acordo com a estimativa de probabilidade de que eles sejam relevantes à consulta

$$P(R \mid d, q)$$

d é relevante se $P(R \mid d, q) > P(NR \mid d, q)$

Ranqueamento

- De maneira mais específica, precisamos saber como as estatísticas que podemos calcular influenciam na relevância do documento



tf, df, tamanho do doc, etc.

- Como computar estas probabilidades??

Ranqueamento

- A medida usada para ranquear os documentos é o Retrieval Status Value (RSV)/Valor do Estado da Recuperação.

$$RSV = \log \prod_{x_i=q_i=1} \frac{p_i(1-u_i)}{u_i(1-p_i)} = \sum_{x_i=q_i=1} \log \frac{p_i(1-u_i)}{u_i(1-p_i)}$$

Probabilidade do termo ocorrer em um documento relevante

Probabilidade do termo ocorrer em um documento não-relevante

$$c_i = \log \frac{p_i(1-u_i)}{u_i(1-p_i)} = \log \left(\frac{p_i}{1-p_i} \right) + \log \left(\frac{1-u_i}{u_i} \right)$$

Relevantes

Não- Relevantes

Para cada termo i , como calcular c_i ?

Independência binária

- Este é o modelo tradicionalmente usado com o Princípio de ranking probabilístico.
 - **Binary** quer dizer booleano, i.e. documentos são representados como vetores de termos cujas incidências são representadas por 0 ou 1. É possível que mais de um documento tenha portanto o mesmo vetor
 - **Independence** significa que os termos ocorrem nos documentos de maneira independente; i.e. o fato de um termo aparecer em um documento não tem nenhum impacto sobre a ocorrência de outros termos no documento.

Estimando C_i – Peso dos Termos

- Para cada termo i consultar a tabela de contingência:

Docs	Relevante	Não relevante	Total
<i>Termo presente $x_i=1$</i>	s	df_i-s	df_i
<i>Termo ausente $x_i=0$</i>	$S-s$	$N-df_i-S+s$	$N-df_i$
Total	S	$N-S$	N

- Assumindo que: $p_i=s/S$ e $u_i=(df_i-s)/(N-S)$

$$c_i = \log \frac{s/(S-s)}{(df_i-s)/(N-df_i-S+s)}$$

Estimando C_i – Peso dos Termos

- Para cada termo i consultar a tabela de contingência:

Docs	Relevante	Não relevante	Total
<i>Termo presente $x_i=1$</i>	s	$df_i - s$	df_i
<i>Termo ausente $x_i=0$</i>	$S - s$	$N - df_i - S + s$	$N - df_i$
Total	S	$N - S$	N

- Assumindo que: $p_i = s/S$ e $u_i = (df_i - s)/(N - S)$

Soma-se 0.5 a cada termo na presença de incerteza

$$c_i = \log \frac{(s + 0.5) / (S - s + 0.5)}{(df_i - s + 0.5) / (N - df_i - S + s + 0.5)}$$

Estimando C_i – Peso dos Termos

Exemplo:

relevantes



Docs Termos	Tom e Jerry	Super Mouse	Garfield	Scooby Doo	PiuPiu e Frajola	Mônica
Cachorro	1	0	1	1	0	1
Casa	1	0	1	0	1	1
Gato	1	0	1	0	1	0
Menino	0	0	0	1	0	1
Passarinho	0	0	0	0	1	0
Rato	1	1	0	0	0	0

Consulta: cachorro gato rato

$$c_i = \log \frac{(s + 0.5)/(S - s + 0.5)}{(df_i - s + 0.5)/(N - df_i - S + s + 0.5)}$$

Termo	C_i
Cachorro	- 0.3679
Gato	1.066
Rato	-0.6989

Estimando C_i – Peso dos Termos

Exemplo:

relevantes

Docs Termos	Tom e Jerry	Super Mouse	Garfield	Scooby Doo	PiuPiu e Frajola	Mônica
Cachorro	1	0	1	1	0	1
Casa	1	0	1	0	1	1
Gato	1	0	1	0	1	0
Menino	0	0	0	1	0	1
Passarinho	0	0	0	0	1	0
Rato	1	1	0	0	0	0

Termo	C_i
Cachorro	- 0.3679
Gato	1.066
Rato	-0.6989

Consulta: cachorro gato rato

$$c_i = \log \frac{(s + 0.5)/(S - s + 0.5)}{(df_i - s + 0.5)/(N - df_i - S + s + 0.5)}$$

$$c_{cachorro} = \log \frac{(1 + 0.5)/(2 - 1 + 0.5)}{(4 - 1 + 0.5)/(6 - 4 - 2 + 1 + 0.5)} = \log \frac{1}{2,33} = \underline{-0,3679}$$

$$c_{gato} = \log \frac{(2 + 0.5)/(2 - 2 + 0.5)}{(3 - 2 + 0.5)/(6 - 3 - 2 + 2 + 0.5)} = \log \frac{5}{0,4285} = \underline{1,0669}$$

$$c_{rato} = \log \frac{(0 + 0.5)/(2 - 0 + 0.5)}{(2 - 0 + 0.5)/(6 - 2 - 2 + 0 + 0.5)} = \log \frac{0,2}{1} = \underline{-0.6989}$$

Estimando C_i – Peso dos Termos

Exemplo:

relevantes

Docs Termos	Tom e Jerry	Super Mouse	Garfield	Scooby Doo	PiuPiu e Frajola	Mônica
Cachorro	1	0	1	1	0	1
Casa	1	0	1	0	1	1
Gato	1	0	1	0	1	0
Menino	0	0	0	1	0	1
Passarinho	0	0	0	0	1	0
Rato	1	1	0	0	0	0

Termo	C_i
Cachorro	- 0.3679
Gato	1.066
Rato	-0.6989

Consulta: cachorro gato rato

$$c_i = \log \frac{s / (S - s)}{(df_i - s) / (N - df_i - S + s)}$$

$$c_{cachorro} = \log \frac{(1 + 0.5) / (2 - 1 + 0.5)}{(4 - 1 + 0.5) / (6 - 4 - 2 + 1 + 0.5)} = \log \frac{1}{2.33} = \underline{-0.3679}$$

$$c_{gato} = \log \frac{(2 + 0.5) / (2 - 2 + 0.5)}{(3 - 2 + 0.5) / (6 - 3 - 2 + 2 + 0.5)} = \log \frac{5}{0.4285} = \underline{1.0669}$$

$$c_{rato} = \log \frac{(0 + 0.5) / (2 - 0 + 0.5)}{(2 - 0 + 0.5) / (6 - 2 - 2 + 0 + 0.5)} = \log \frac{0.2}{1} = \underline{-0.6989}$$

Ranque dos documentos???

Ranqueamento – Peso dos documentos

Termo	c_i
Cachorro	- 0.3679
Gato	1.0669
Rato	-0.6989

$$RSV = \sum_{x_i=q_i=1} c_i$$

Doc	RSV	Rank
Tom e Jerry	- 0.3679(cachorro) + 1.0669(gato) - 0.6989(rato) = <u>0.0001</u>	
Super Mouse	- 0.6989(rato) = <u>-0.6989</u>	
Garfield	- 0.3679(cachorro) + 1.0669(gato) = <u>0.6990</u>	
Scooby Doo	- 0.3679(cachorro) = <u>- 0.3679</u>	
PiuPiu e Frajola	1.0669(gato) = <u>1.0669</u>	
Mônica	- 0.3679(cachorro) = <u>- 0.3679</u>	

Ranqueamento – Peso dos documentos

Termo	c_i
Cachorro	- 0.3679
Gato	1.0669
Rato	-0.6989

$$RSV = \sum_{x_i=q_i=1} c_i$$

Doc	RSV	Rank
Tom e Jerry	- 0.3679(cachorro) + 1.0669(gato) - 0.6989(rato) = <u>0.0001</u>	3°
Super Mouse	- 0.6989(rato) = <u>-0.6989</u>	6°
Garfield	- 0.3679(cachorro) + 1.0669(gato) = <u>0.6990</u>	2°
Scooby Doo	- 0.3679(cachorro) = <u>- 0.3679</u>	5°
PiuPiu e Frajola	1.0669(gato) = <u>1.0669</u>	1°
Mônica	- 0.3679(cachorro) = <u>- 0.3679</u>	4°

Questões importantes

- Como saber quantos documentos relevantes existem e quais são eles?
 - Pode-se fazer uma estimativa inicial
 - Exemplo: $p_i = 0.5$ e $u_i = df_t / N$
 - Ou podemos fazer uma recuperação inicial de acordo com o modelo vetorial e supor que os top k documentos são relevantes
 - O processo pode ser iterativo (com ou sem a interferência do usuário).
 - Neste caso, a cada iteração as estimativas ficam mais precisas.

Vantagens x Desvantagens

- **Vantagens**

- Os documentos são ranqueados de acordo com sua probabilidade de serem relevantes, com base na informação disponível ao sistema.

- **Desvantagens**

- Relevância de um documento é afetada por diversos fatores externos, não somente na informação disponível ao sistema;
- Necessidade de estimar a separação inicial dos documentos em conjuntos relevantes e não relevantes;
- Não leva em consideração a frequência na qual um termo de indexação ocorre em um documento;
- Falta de normalização pelo tamanho dos documentos.

Comparação entre os modelo

- O modelo booleano é considerado como o mais fraco
- Há controvérsias quanto ao melhor modelo
- Croft realizou experimentos e concluiu que o modelo probabilístico é melhor
- Logo após, Salton & Buckley realizaram experimentos e concluíram que o modelo vetorial *deve* ser melhor para coleções gerais.